AI-lytics - Dokumentacja projektu

Picipolo:
Mikołaj Gałkowski
Wiktor Jakubowski
Łukasz Tomaszewski

Spis treści

1 Opis projektu

Projekt obejmuje rozwiązanie oparte o Generatywną Sztuczną Inteligencję, która ma na celu ułatwić proces eksploracji i analizy danych. Narzędzie udostępnia aplikację webową, która pozwala na interakcję z ChatBot'em, który odpowiada na zapytania użytkownika w oparciu o schemat bazy danych SQL. Przy pomocy różnych komponentów użytkownik może poprosić Sztuczną Inteligencję o opisanie bazy danych, wygenerowanie odpowiedniego zapytania SQL, a także wygenerowanie wykresu na podstawie wygenerowanych zapytań. Wszystkie te rzeczy generowane są na podstawie języka naturalnego, dzięki czemu użytkownik aplikacji nie musi posiadać technicznej wiedzy w celu analizy danych. Kod naszego rozwiązania znajduje się na repozytorium GitHub.

2 Architektura rozwiązania

Na Figurze 1 przedstawiona została architektura naszego rozwiązania. wykorzystaliśmy Azure Container Instances do wdrożenia aplikacji Streamlit z możliwością konwersacji. W celu wykorzystania AI, połączyliśmy się za pomocą API Key do usług Azure OpenAI (GPT-3.5) oraz do PandasAI. Połączyliśmy naszą aplikację z bazą danych. Skonfigurowane zostały Network Security Groups i podsieci VNet do komunikacji pomiędzy aplikacją a bazą danych. Zastosowana została także filtracja ruchu (blokowanie zapytań do API modeli i bazy danych z innych adresów IP niż aplikacji).

3 Aplikacja i jej właściwości

Aplikacja webowa oferuje 3 widoki: Chat z Pamięcią, Chat generujący zapytania SQL wraz z generowaniem wizualizacji oraz Chat z ReActem. Dodatkowo przy każdym zapytaniu wyświetlany jest jego koszt.

Chat z pamięcią pozwala na prowadzenie konwersacji z AI. Do zapytań przekazywany jest pobrany z bazy danych schemat, na podstawie którego AI generuje zapytania, wywołuje je oraz analizuje ich zawartość i prezentuje wyniki analizy w przystępny dla użytkownika sposób (Figura **??**).

Kolejny chat generuje zapytania SQL na podstawie zapytań w języku naturalnym. Następnie wyniki tych zapytań przekazywane są do PandasAI, który generuje wykres na podstawie tych danych (Figura 3).

Ostatnim chatem jest Agent wykorzystujący framework do promptowania ReAct (Reasoning + Act). W wyniku iteracyjnych zapytań poprawia on sekwencyjnie swojego prompta, co pozwala na otrzymanie lepszych rezultatów.

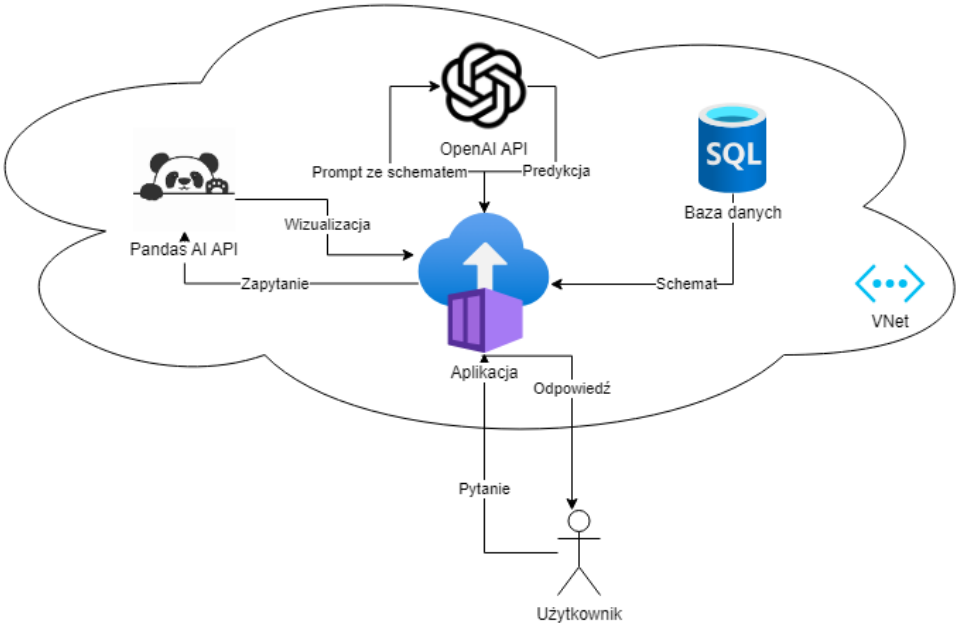

Rysunek 1: Diagram architektury rozwiązania

4 Testy bezpieczeństwa i jakości

Kod naszej aplikacji sprawdzony został przy użyciu GitGuardian. Narzędzie to sprawdza czy w kodzie nie występują wrażliwe informacje takie jak hasła czy endpointy. Przykładowe wywołanie przedstawione zostało na Figurze 4. Wykryło ono dwa zagrożenia, które zostały przez nas usunięte.

Nasz kod sprawdzany jest także na poziomie GitHuba. Każdy PR wymaga weryfikacji przez GitGuardian (Figura 5) oraz sprawdzana jest jakość kodu. Wykorzystywane do tego są narzędzia Black, Isort oraz Flake8, których działanie przedstawione zostało na Figurze 6

Ostatnim etapem jest sprawdzenie podatności oraz nieścisłości infrastruktury chmurowej. W tym celu wykorzystywany jest Microsoft Defender for Cloud, który generuje rekomendacje dotyczące architektury oraz ich wagę. Działanie tego narzędzia przedstawione zostało na Figurze 7.

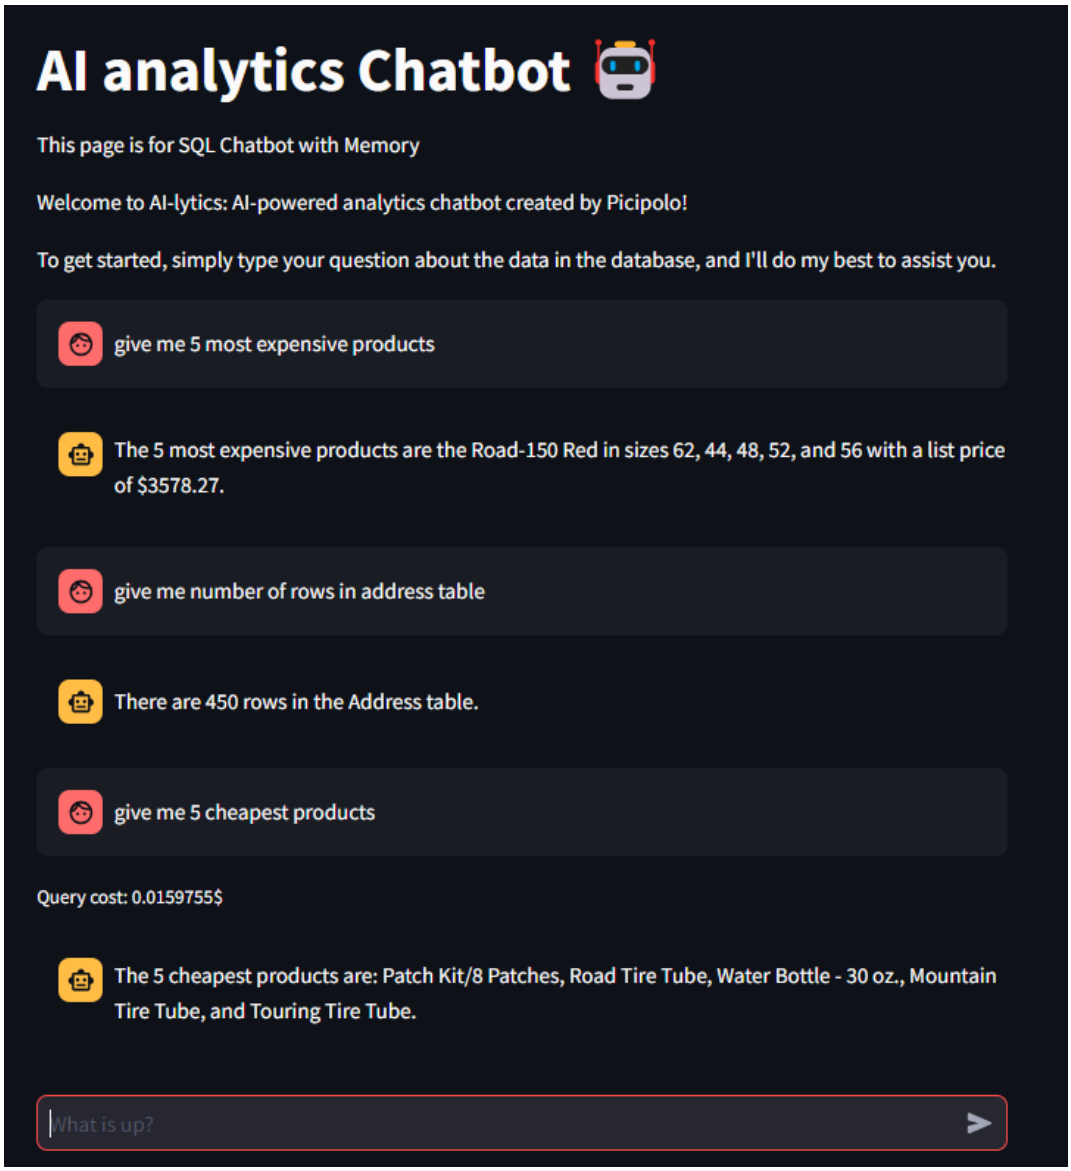

Rysunek 2: Chat z Pamięcią

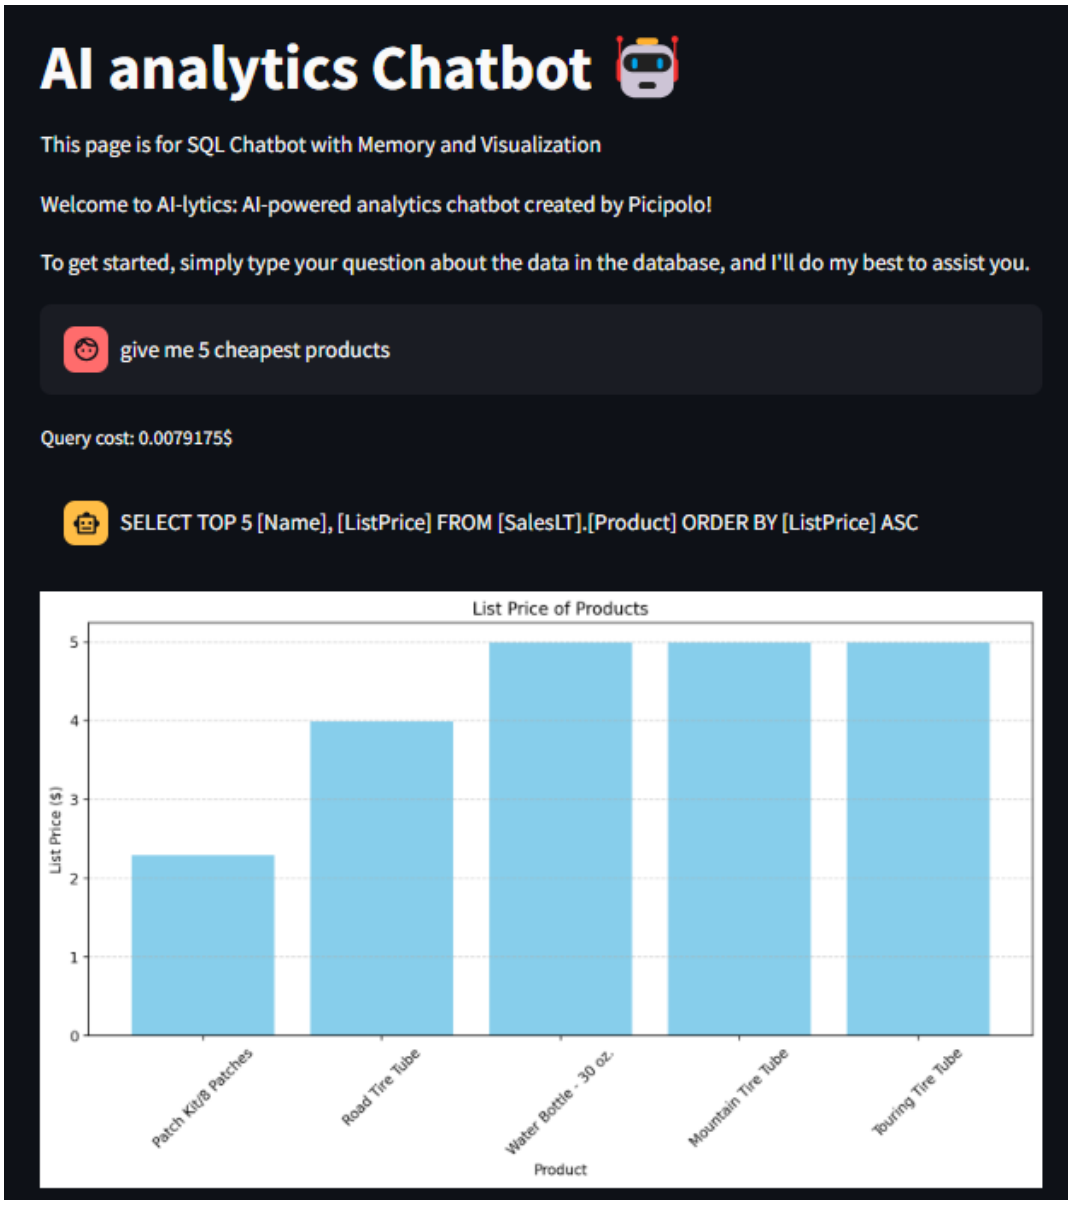

Rysunek 3: Chat generujący zapytania SQL

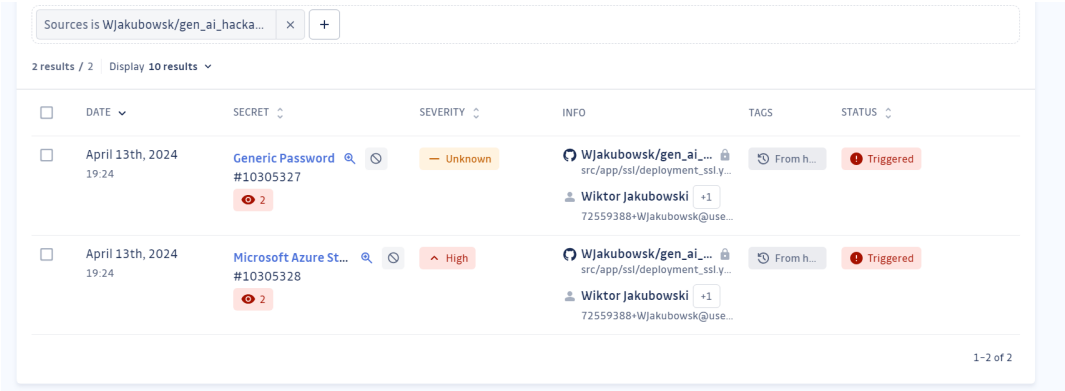

Rysunek 4: Przykładowe wywołanie GitGuardian

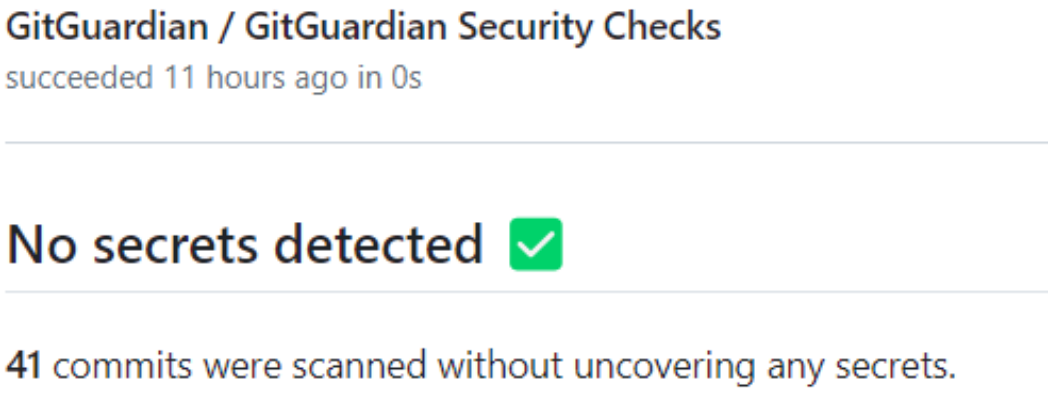

Rysunek 5: GitGuardian - wywołanie w GitHub

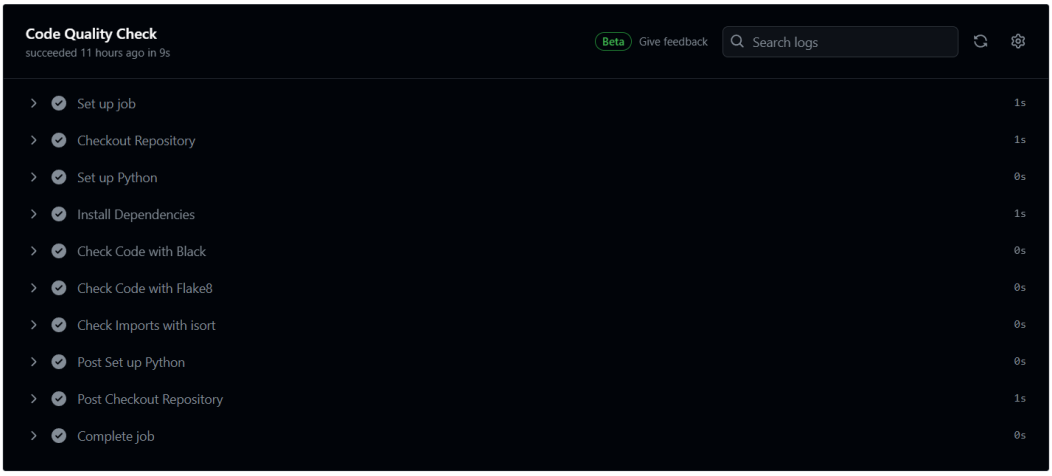

Rysunek 6: Weryfikacja jakości kodu

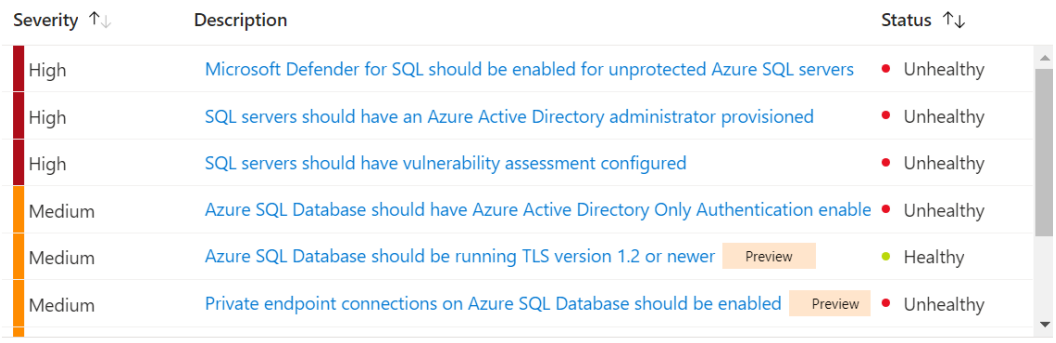

Rysunek 7: Rekomendacje wygenerowane przez Microsoft Defender for Cloud